

Traitement et Visualisation des Données

Comprendre les comportements face aux campagnes de phishing

Exercice pédagogique de sensibilisation au phishing - Données synthétiques uniquement

Mateo Burnichon | Escen - Bachelor Web & Technologies | Décembre 2025

1. Introduction · 2. Préparation · 3. Nettoyage · 4. Anomalies · 5. Analyse · 6. Datatelling · 7. Conclusions

Pourquoi ce projet ?

Des données brutes ne disent rien. C'est leur traitement qui révèle les patterns et les comportements cachés. On explore comment l'âge, les intérêts et les canaux influencent la réception de campagnes de phishing.

Les données de départ

519 observations : 8 colonnes de métadonnées (âge, intérêts, canal préféré) et 1 variable cible (succès). Simple mais puissant.

Empreinte mémoire initiale : **0.039 Mo**

Optimisation des types

Première étape : choisir les bons types. On convertit les scores en **float32**, les identifiants en **int32** et les textes en **category**.

Résultat : l'empreinte passe à **0.016 Mo** (réduction de **59%**). Pandas respire mieux, les calculs deviennent plus rapides.

Nettoyage des données

0 doublons trouvés — parfait.

6 valeurs manquantes supprimées — on passe à 513 lignes.

Standardisation des textes et vérification de la cohérence.

Impact : 519 → 513 lignes exploitables.

Anomalies : quand les données deviennent suspectes

Méthode : **IQR** ($Q3 + 1.5 \times (Q3 - Q1)$). Plus robuste que Z-score.

On cherche les scores extrêmes, les âges impossibles, les valeurs qui sortent du cadre.

Scores jeu	Design	Football	Âge	Total
6	3	3	120	127

Après suppression : **388 lignes** exploitables.

L'analyse révèle les patterns

Taux global de réussite : 68.3%

Par produit : Fortnite (70.2%) > Fifa (69.5%) > Instagram Pack (66%)

Par canal : Facebook (85.8%) >> Mail (66%) > Instagram (62%)

Par âge : 45-60 ans (77%) — le groupe le plus vulnérable

Corrélations : Gaming (0.48) > Design (0.32) > Football (0.28)

Datatelling : trois profils clés

1. Le Joueur (28 ans, Gaming +80)

→ Fortnite/Facebook = 75.9% de succès

2. Le Fan de Foot (52 ans, Football +60)

→ Fifa/Facebook = 76% de succès

3. Le Digital Native (22 ans, Design +50)

→ Instagram Pack = 68% de succès

Conclusions

- ✓ Facebook domine nettement (85.8% vs autres canaux)
- ✓ Les 45-60 ans sont plus vulnérables qu'on ne le pense
- ✓ Personnaliser par intérêt augmente significativement l'efficacité
- ✓ Les jeunes joueurs cliquent plus facilement

Ce qu'on a appris : De la donnée brute à une stratégie ciblée. L'importance de nettoyer rigoureusement. Comment les patterns statistiques révèlent les comportements humains.

Exercice pédagogique dans un cadre de sensibilisation au phishing. Données 100% synthétiques.

Mateo Burnichon - Décembre 2025